

Simetría de Hopfield: por qué los complementos son estados estables

SIA-TP4 — Aprendizaje No Supervisado

Función de energía

La energía de una configuración $\mathbf{S} \in \{-1, +1\}^N$ en una red de Hopfield con pesos $\mathbf{W} \in \mathbb{R}^{N \times N}$ se define como:

$$\mathcal{H}(\mathbf{S}) = -\frac{1}{2} \sum_{i,j} W_{ij} S_i S_j$$

Donde la doble suma recorre todos los pares de neuronas. Como $\mathbf{W}$ es simétrica ($W_{ij} = W_{ji}$) y la diagonal está en cero ($W_{ii} = 0$), cada par (i, j) con $i \neq j$ aparece dos veces y contribuye con $W_{ij} S_i S_j$ en ambos sentidos.

Invariancia ante $\mathbf{S} \rightarrow -\mathbf{S}$

Reemplazo $\mathbf{S}$ por su complemento $-\mathbf{S}$ (todos los píxeles invertidos):

$$\begin{aligned} \mathcal{H}(-\mathbf{S}) &= -\frac{1}{2} \sum_{i,j} W_{ij} (-S_i)(-S_j) \\ &= -\frac{1}{2} \sum_{i,j} W_{ij} S_i S_j \\ &= \mathcal{H}(\mathbf{S}). \end{aligned}$$

La doble negación se cancela: $(-1) \cdot (-1) = +1$. Por lo tanto $\mathcal{H}$ es **invariante** ante el cambio global de signo del estado.

Consecuencia. Cualquier mínimo local $\mathbf{S}^*$ tiene un mínimo gemelo $-\mathbf{S}^*$ con exactamente la misma energía. El paisaje de energía es simétrico respecto del origen, como un par de pozos espejados.

Misma simetría en la regla de actualización

La actualización síncrona es $\mathbf{S}_{t+1} = \text{sign}(\mathbf{W} \mathbf{S}_t)$. Si ξ es un estable, entonces $\text{sign}(\mathbf{W} \xi) = \xi$, y:

$$\text{sign}(\mathbf{W} \cdot (-\xi)) = \text{sign}(-\mathbf{W} \xi) = -\text{sign}(\mathbf{W} \xi) = -\xi.$$

Por cada patrón almacenado ξ^μ , su complemento $-\xi^\mu$ también es estable. Con p patrones almacenados, la red tiene $2p$ estados estables garantizados por esta simetría (más los espurios “mezcla” que aparezcan).

El término $W_{ij} S_i S_j$ en detalle

El argumento de la simetría se entiende mejor mirando un único término de la suma. El producto $S_i S_j$ solo puede tomar dos valores, según si las neuronas i y j están en el mismo estado o no:

S_i	S_j	$S_i S_j$	Término $W_{ij} S_i S_j$
+1	+1	+1	$+W_{ij}$
-1	-1	+1	$+W_{ij}$
+1	-1	-1	$-W_{ij}$
-1	+1	-1	$-W_{ij}$

Lectura. Hay dos casos:

- Si S_i y S_j están **alineados** (ambos +1 o ambos -1), el término aporta $+W_{ij}$.
- Si están **anti-alineados** (uno +1, otro -1), aporta $-W_{ij}$.

El término solo depende de la *compatibilidad relativa* entre S_i y S_j , no de sus signos absolutos. Si das vuelta los dos factores a la vez ($S_i \rightarrow -S_i$ y $S_j \rightarrow -S_j$), $S_i S_j$ no cambia. Por eso, cuando complementás *toda* la red, cada término $W_{ij} S_i S_j$ queda exactamente igual, y la suma global —que es $-2\mathcal{H}$ — también.

Ejemplo concreto ($N = 4$)

Un único patrón almacenado:

$$\mathbf{S}^* = \begin{pmatrix} +1 \\ +1 \\ -1 \\ +1 \end{pmatrix}, \quad -\mathbf{S}^* = \begin{pmatrix} -1 \\ -1 \\ +1 \\ -1 \end{pmatrix}.$$

Pesos construidos con la regla de Hebb $\mathbf{W} = \frac{1}{N} \mathbf{S}^* \mathbf{S}^{*\top}$ y diagonal puesta en cero:


$$\mathbf{W} = \frac{1}{4} \begin{pmatrix} 0 & +1 & -1 & +1 \\ +1 & 0 & -1 & +1 \\ -1 & -1 & 0 & -1 \\ +1 & +1 & -1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & +0,25 & -0,25 & +0,25 \\ +0,25 & 0 & -0,25 & +0,25 \\ -0,25 & -0,25 & 0 & -0,25 \\ +0,25 & +0,25 & -0,25 & 0 \end{pmatrix}.$$

Calculando energía y aplicando la regla:

Estado	$\mathcal{H}(\cdot)$	$\text{sign}(\mathbf{W} \cdot \cdot)$
$\mathbf{S}^* = (+1, +1, -1, +1)$	-1,50	$\mathbf{S}^*$ (estable)
$-\mathbf{S}^* = (-1, -1, +1, -1)$	-1,50	$-\mathbf{S}^*$ (estable)
$(+1, -1, +1, -1)$ (arbitrario)	0,00	no es estable

Los dos estados (patrón y complemento) tienen la misma energía -1,5, y ambos son estados estables. **La única decisión humana fue almacenar $\mathbf{S}^*$** ; el complemento aparece solo, como consecuencia de la simetría de $\mathbf{W}$.

Visualización del paisaje



Las dos cuencas son espejos una de la otra. Cualquier input con $p_{\text{flip}} < 0,5$ cae en la cuenca de S^* ; con $p_{\text{flip}} > 0,5$ cae en la cuenca de $-S^*$. El input está más cerca, en Hamming, del complemento que del original.

Implicancia para los experimentos del TP

En los CSV el complemento queda etiquetado como `outcome=Espurio`, porque la definición operativa de “espurio” es “*no es ninguno de los patrones almacenados*”. Esto es correcto. Pero conviene tener presente:

- El complemento no es un espurio “accidental”: aparece *garantizado* por la simetría de $\mathcal{H}$.
- Para la consigna 2.1.b (identificar un estado espúreo) preferimos destacar un caso de *mezcla*, con hamming intermedio respecto de todos los almacenados, en vez de un complemento puro (`hamming_final` = 25 contra el original).
- Si en alguna slide aparece un complemento, alcanza con mencionar la simetría de $\mathcal{H}$ sin necesidad de profundizar.