

Análisis PCA sobre europe.csv

Documento para entender qué se hizo, qué se obtuvo y cómo se interpreta.
Todo apoyado en lo visto en la clase (PDF "5 - PCA" y transcripción del audio).

1. Qué nos pidieron (slide 47)

Sobre el dataset `europe.csv` (28 países × 7 variables: Area, GDP, Inflation, Life.expect, Military, Pop.growth, Unemployment), usar una librería para **calcular las componentes principales e interpretar PC1 gráfica y teóricamente**.

2. Por qué tiene sentido aplicar PCA acá (slides 13, 16)

PCA sirve cuando hay **redundancia** entre variables, es decir, cuando varias columnas se mueven juntas y cuentan parte de la misma historia. Si las variables no estuvieran correlacionadas, no tendría sentido aplicar el método.

En `europe.csv` se ve fácil: países con GDP alto tienden a tener mayor expectativa de vida, menos inflación, menos desempleo. Eso es redundancia.

3. Procedimiento aplicado (slide 32)

Se siguieron al pie de la letra los 7 pasos del procedimiento de cátedra:

1. **Construir la matriz X** con las 7 variables en columnas (28 filas, una por país).
2. **Estandarizar** cada columna: $(x - \text{media}) / \text{desvío}$.
3. **Calcular la matriz de correlaciones Sx**.
4. **Calcular autovalores y autovectores** de Sx.
5. **Ordenar los autovalores de mayor a menor**.
6. **Construir la matriz V** con los autovectores ordenados.
7. **Calcular las componentes Y** como combinación lineal de las variables originales.

Por qué estandarizar (slides 24-27)

Las variables del dataset tienen escalas muy distintas: Area en cientos de miles de km², GDP en decenas de miles de dólares, Inflation en porcentajes. Si no se estandariza, las variables con magnitudes grandes (Area, GDP) **dominan la varianza solo por su escala**, no por su variabilidad real.

Estandarizar equivale a aplicar PCA sobre la **matriz de correlaciones** en lugar de la matriz de covarianzas. Es lo recomendado cuando las variables tienen distintas unidades.

4. Lo que se obtuvo

4.1 Matriz de correlaciones S_x

Lo primero útil que sale es **leer la matriz S_x** (en `Notas/matriz_correlaciones.md`). Los pares más fuertes (en módulo cerca de 1, slide 10):

Par	r	Lectura
Life.expect ↔ Pop.growth	+0.77	mayor expectativa de vida ↔ mayor crecim.
GDP ↔ Pop.growth	+0.76	mayor PBI ↔ mayor crecimiento
GDP ↔ Life.expect	+0.70	mayor PBI ↔ mayor expectativa de vida
Life.expect ↔ Inflation	-0.68	mayor expectativa de vida ↔ menor inflación
GDP ↔ Unemployment	-0.53	mayor PBI ↔ menor desempleo

Hay redundancia clara → PCA aplica.

4.2 Autovalores y proporción de varianza (slides 23, 31)

Cada autovalor es la **varianza de su componente**. La proporción explicada por cada componente es $\lambda_i / \sum \lambda_i$.

Componente	λ_i	% varianza	% acumulado
PC1	3.2272	46.10%	46.10%
PC2	1.1871	16.96%	63.06%
PC3	1.0632	15.19%	78.25%
PC4	0.7704	11.01%	89.26%
PC5	0.4578	6.54%	95.80%
PC6	0.1687	2.41%	98.21%
PC7	0.1256	1.79%	100.00%

PC1 sola explica el 46% de la variabilidad del dataset. Con PC1+PC2 se alcanza el 63%, lo que justifica trabajar en pocas dimensiones.

4.3 Cargas de PC1 (primer autovector, slide 21)

$$Y1 = -0.125 \cdot \text{Area} + 0.500 \cdot \text{GDP} - 0.407 \cdot \text{Inflation} + 0.483 \cdot \text{Life.expect} \\ - 0.188 \cdot \text{Military} + 0.476 \cdot \text{Pop.growth} - 0.272 \cdot \text{Unemployment}$$

- Cargas **positivas grandes**: GDP (+0.50), Life.expect (+0.48), Pop.growth (+0.48).
- Cargas **negativas notables**: Inflation (-0.41), Unemployment (-0.27).
- Cargas **chicas**: Area (-0.12), Military (-0.19) → casi no influyen en PC1.

4.4 Verificación de que se eliminó la redundancia (slide 14)

Calculamos la matriz de correlaciones de las Y y dio la identidad (ceros fuera de la diagonal, con error numérico $\sim 10^{-15}$). Eso confirma que las nuevas variables son no correlacionadas entre sí, justo el objetivo principal del método (slide 13).

5. Interpretación de PC1

5.1 Interpretación teórica (slides 21, 38)

PC1 es una **combinación lineal de las 7 variables originales** elegida para capturar la mayor varianza posible.

Mirando los signos de las cargas (slide 38):

- Variables con **carga positiva** se correlacionan positivamente con PC1.
→ países con valores altos en GDP, Life.expect, Pop.growth tendrán Y1 alto.
- Variables con **carga negativa** se correlacionan negativamente con PC1.
→ países con Inflation y Unemployment altos tendrán Y1 bajo.

PC1 funciona como un **índice** (slide 38: *"la primera componente representa un índice por el cual se pueden ordenar los registros"*). En el ejemplo de la clase (slide 37) PC1 representaba "capacidad de gasto" de las provincias. En nuestro caso, podemos interpretarlo como un **índice de nivel de desarrollo socioeconómico**: un solo número que combina riqueza, calidad de vida y estabilidad económica.

5.2 Interpretación gráfica (gráfico de barras de Y1, slide 46)

Al calcular Y1 para cada país y ordenarlos, el ranking queda:

Top 5 (Y1 más alto)	Y1	Bottom 5 (Y1 más bajo)	Y1
Luxembourg	+3.42	Ukraine	-4.50
Switzerland	+3.22	Bulgaria	-2.56

Top 5 (Y1 más alto)	Y1	Bottom 5 (Y1 más bajo)	Y1
Norway	+2.07	Estonia	-2.44
Netherlands	+1.81	Latvia	-2.26
Ireland	+1.78	Lithuania	-1.50

La separación visual es clara:

- **Y1 positivo y grande** → países de Europa occidental y nórdica de altos ingresos.
- **Y1 cercano a 0** → países del sur (España, Italia, Portugal) y algunos del centro-este de la UE.
- **Y1 negativo y grande** → países del este post-soviético y Ucrania.

PC1 ordena los países, sin que se lo hayamos pedido explícitamente, en el mismo sentido que cualquier ranking informal de "desarrollo en Europa".

5.3 Sobre el signo del autovector (slide 46)

En nuestro caso el autovector salió orientado de forma natural ("más desarrollo = Y1 positivo"). Si la librería hubiera devuelto el autovector opuesto, habría que **invertir el signo** y aclararlo, tal como hace la clase en la slide 46 con la nota "autovector opuesto". Matemáticamente v y $-v$ son ambos autovectores válidos.

6. Casos puntuales que ayudan a entender PC1

Finlandia (Y1 = +0.21) queda casi en el centro, sorprendentemente baja para ser nórdica. La razón es que PC1 no es "ser rico"; es una mezcla. En Finlandia el GDP es modesto comparado con Luxemburgo o Noruega, y el crecimiento poblacional es casi nulo (0.07), lo que pesa porque Pop.growth tiene carga positiva grande. Esto ilustra el mensaje de slide 38: PC1 es un índice combinado, y los resultados pueden contradecir la intuición sobre variables aisladas.

7. Reducción de dimensión efectiva (slides 16, 23)

- Originalmente: 7 variables → $28 \times 7 = 196$ valores.
- Con solo PC1: $28 \times 1 = 28$ valores, y conservamos el 46% de la variabilidad.
- Con PC1 + PC2: $28 \times 2 = 56$ valores, y conservamos el 63%.

Hay una **pérdida de información** controlada (slide ~147 del transcript: *"hay cierta pérdida de información (...) pero se puede medir y no es tan relevante"*), pero a cambio se obtiene un dataset mucho más fácil de visualizar e interpretar, sin la redundancia original.

8. Resumen ejecutivo (para arrancar la presentación)

- Aplicamos PCA sobre `europe.csv` (28 países × 7 variables).
- Estandarizamos las variables porque las escalas eran muy distintas.
- La matriz de correlaciones mostró redundancia clara (GDP, Life.expect y Pop.growth fuertemente correlacionadas entre sí).
- PC1 explica el **46.1%** de la varianza total.
- Las variables que más pesan en PC1 son GDP, Life.expect, Pop.growth (signo +) e Inflation, Unemployment (signo -).
- PC1 actúa como un índice de **nivel de desarrollo socioeconómico**: ordena los países desde Luxemburgo y Suiza (más desarrollados) hasta Ucrania (menos).
- Las componentes Y resultantes no están correlacionadas entre sí — se eliminó la redundancia del dataset original.

9. Archivos generados

Archivo	Contenido
<code>pca_europe.py</code>	Script con todos los cálculos
<code>boxplot_original.png</code>	Boxplot de las variables originales
<code>boxplot_estandarizado.png</code>	Boxplot tras estandarizar
<code>pc1_por_pais.png</code>	Gráfico de barras de Y1 por país (slide 46)
<code>biplot.png</code>	Biplot PC1 vs PC2 (slide 45)
<code>Notas/matriz_correlaciones.md</code>	Matriz Sx + cálculo de referencia s_11
<code>Notas/autovalores_autovectores.md</code>	Autovalores, V y componentes Y
<code>PCA_europe_seguimiento.pptx</code>	Presentación con el seguimiento de pasos